

Producción petrolera con evidencia y contexto

Proyecto final: análisis exploratorio y dashboard

GRUPO 5

Corte analítico: producción enero 2022-agosto 2026; precio enero 2021-julio 2026.

Documento actualizado el 2 de octubre de 2026 (hora de Ecuador).

88,30 millones	51,75%	789 registros
Barriles observados en enero-agosto de 2026.	Crudo concentrado en SA, AU y SH durante ese período.	Claves activo-mes después de consolidar 13 filas redundantes.

Pregunta principal

¿Qué mejoras y oportunidades de mejora pueden identificarse a partir de las variaciones de producción, al comparar períodos equivalentes y considerar la cobertura y calidad de los datos?

Resultado principal

En los 14 activos con ocho meses completos en ambos años, la tasa diaria conjunta aumenta **7.53%** entre enero-agosto de 2025 y 2026. Indillana registra una variación de **-6.25%**. Las diferencias son descriptivas; los archivos no identifican las causas.

Entrega

Este documento integra contexto, fuentes, diccionario, siete pasos EDA, ocho apartados técnicos, dashboard, cinco preguntas complementarias con gráficos, cuatro decisiones y reproducción. El notebook incluye código ejecutado y salidas. El repositorio conserva las tres fuentes originales con SHA-256.

Repositorio: https://github.com/residenterick681/proyecto_final_Dashboard_EDA

Dashboard: https://residenterick681.github.io/proyecto_final_Dashboard_EDA/

Alcance: registros aportados por el usuario; no equivalen a toda la producción nacional. Las unidades de producción se interpretan con apoyo de la ficha pública, sin certificación de identidad de archivos.

1. Contexto, usuario y origen de los datos

La planificación petrolera requiere distinguir la evolución de los volúmenes de los cambios en la cobertura de activos, la duración de cada mes y los problemas de registro. Un total anual parcial puede inducir decisiones equivocadas si se compara directamente con un año completo.

Usuario identificado: analista de planificación y supervisión de producción de una operación petrolera. Utilizaría el dashboard para priorizar revisiones de medición y continuidad operativa; no para aprobar inversiones o diagnosticar fallas únicamente con estas tablas.

Fuente entregada	Contenido y cobertura	Tratamiento
eppec_prd_petroleo_acumulada_2026 (2).xlsx	802 filas; 5 columnas con datos; 16 códigos; enero 2022-agosto 2026. Hoja1.	Una clave por año-mes-activo; se conserva la fila de origen.
precio-petroleo-crudo-ecu (1).csv	67 precios mensuales, enero 2021-julio 2026; USD por barril.	Clave de mes única. Unión izquierda a producción.
activos_nomenclatura.csv	15 códigos y nombres.	Unión muchos-a-uno. AB16 queda sin nombre validado.

Cómo se interpreta una mejora

En este análisis, una mejora observada del nivel productivo es un aumento de la tasa de crudo por día calendario entre períodos equivalentes y los mismos activos. Una oportunidad de mejora es una prioridad de investigación o de calidad del dato respaldada por la evidencia. Ninguna de las dos demuestra, por sí sola, mayor eficiencia, rentabilidad o éxito de una intervención.

Procedencia y supuestos explícitos

El nombre del XLSX y la ficha de Datos Abiertos Ecuador son compatibles con producción mensual de EP Petroecuador. La ficha describe BPPM y MPC. Se adoptan barriles por mes y miles de pies cúbicos por mes. Los valores suben y bajan dentro del año, por lo que no se calcula una diferencia de un supuesto acumulado anual. La hoja por sí sola no declara unidades ni metodología; esta limitación permanece visible.

La definición del BCE identifica el precio como promedio ponderado mensual de exportaciones de crudos Oriente y Napo de EP Petroecuador. El CSV entregado explicita USD por barril. Se usa como contexto agregado; no es el precio efectivo de cada activo. No se interpreta precio $\times$ producción como facturación.

Se preservan los tres archivos entregados, sin descargar sustitutos ni atribuir autenticidad byte a byte a una publicación oficial. El catálogo no incluye AB16; no se presume su equivalencia con AIT. Los huecos pueden reflejar cambios de cobertura o de operación y requieren verificación.

Datos observados, no simulados: C2 se cubre mediante origen documentado, script determinista, problemas encontrados y remuestreo analítico con semilla 2026. La semilla no se usa para inventar registros petroleros.

2. Diccionario completo de las fuentes

Unidad de observación: un activo en un mes calendario. La clave original es AÑO + MES + ACTIVO; en la tabla analítica es anio + mes + activo. Los códigos no tienen orden numérico ni significado cuantitativo.

Origen / campo	Tipo y unidad	Definición y regla
producción: AÑO / anio	int64 / año calendario	2022-2026; parte de la clave
producción: MES / mes	int64 / mes calendario	1-12; parte de la clave
producción: ACTIVO / activo	string / código nominal	16 códigos observados; parte de la clave
producción: CRUDO / crudo	float64 / barriles mensuales*	Volumen observado; 1 contradicción queda NA
producción: GAS / gas	float64 / MPC mensuales*	Miles de pies cúbicos; 2 contradicciones quedan NA; cero válido
precio: Período / fecha	datetime64 / primer día del mes	67 meses desde 2021-01 hasta 2026-07; clave única
precio: Precio... / precio_usd_barril	float64 / USD por barril	Indicador mensual agregado, no cotización por activo
catálogo: Activo / nombre_activo	string / nombre nominal	15 nombres; AB16 no está en el catálogo
catálogo: Nomenclatura / activo	string / código nominal	Clave única usada para unión muchos-a-uno

* Las unidades de CRUDO y GAS son interpretaciones respaldadas por la ficha del conjunto mensual (BPPM y MPC), no metadatos internos del XLSX. Se explicita esta diferencia para no dar una certeza que el archivo no contiene.

Conservación y versiones

data/crudos/manifest.json registra nombre original, nombre portable, tamaño y SHA-256. El lector comprueba cada huella antes de ejecutar; una modificación de la fuente detiene el proceso. Actualizar fuentes requiere actualizar el manifiesto y revisar las interpretaciones.

3. Diccionario de la tabla analítica y métricas

Campo derivado	Tipo / unidad	Definición y tratamiento
fecha	datetime64 / primer día del mes	Construida desde anio y mes en producción
filas_origen	string / filas de Excel	Números originales separados por ; encabezado en fila 1
n_filas_origen	int64 / conteo	Cantidad de filas originales consolidadas por clave
conflicto_crudo / conflicto_gas	bool / verdadero/falso	True cuando los valores no son equivalentes; no se elige uno
catalogo_faltante	bool / verdadero/falso	True si el código no coincide con el catálogo
dias_mes	int64 / días calendario	28, 29, 30 o 31; febrero bisiesto incluido
crudo_diario	float64 / barriles por día*	crudo/dias_mes; no mide tasa de días operativos
gas_diario	float64 / MPC por día*	gas/dias_mes; no se suma a crudo
log1p_crudo	float64 / logaritmo transformado	$\ln(1+\text{crudo})$; auxiliar, no volumen físico
trimestre	int64 / trimestre calendario	1,2,3,4; derivado de fecha
atipico_crudo_diario / atipico_gas_diario	bool / verdadero/falso	Fuera de Q1-1,5 IQR o Q3+1,5 IQR dentro de cada activo; se conserva

Métricas de grupos: n_registros = filas del grupo; n_crudo, n_gas y n_precio = observaciones válidas de cada medida. crudo_total/gas_total = suma observada (NA si no existe ningún valor); media_crudo_diario y mediana_crudo_diario = promedio y mediana de las tasas mensuales. grupo_pequeno = n_crudo < 12.

Métricas de períodos: tasa conjunta = suma de volumen / suma de días de meses distintos; participación = volumen del activo / volumen total observado; cambio (%) = $100 \times (\text{tasa actual} / \text{tasa anterior} - 1)$. El precio medio es la media simple de los meses válidos, sin multiplicarlos por activos. No es un promedio ponderado del período.

4. Método EDA: pasos 1 y 2

Se sigue el orden explícito de S3_P1_Ruano.ipynb. La preparación y consolidación se ejecutan antes de los gráficos para no duplicar observaciones; sus decisiones se explican en el paso 5, como en el taller.

Paso del curso	Aplicación al proyecto
1. Pregunta de análisis	Problema profesional, usuario, pregunta y alcance.
2. Origen y estructura	Fuentes, unidad activo-mes, tipos y diccionario.
3. Análisis univariado	Distribución, media, mediana, dispersión y asimetría.
4. Análisis bivariado	Producción por activo y relación temporal con el precio.
5. Calidad de los datos	Faltantes, duplicados, contradicciones y atípicos.
6. Segmentación	Activo y año, tamaños válidos y comparación de períodos equivalentes.
7. Hallazgos y decisiones	Evidencia, acción, responsable, indicador y límite.

Paso 1: pregunta y unidad

¿Qué mejoras y oportunidades de mejora pueden identificarse a partir de las variaciones de producción, al comparar períodos equivalentes y considerar la cobertura y calidad de los datos?

```
raw, prices_raw, catalog = load_sources(ROOT)
print(raw.shape, prices_raw.shape, catalog.shape)
raw.info()
raw.describe(include='all')
```


Paso 2: resultado e interpretación

La lectura devuelve (802, 5), (67, 2) y (15, 2). Hay 56 meses de producción y 16 activos observados en distintas ventanas. Excel tiene formato hasta la columna Q, pero solo A:E contienen datos; el lector ignora el resto. Los precios de 2021 no tienen producción correspondiente y no se fuerzan al panel. Agosto de 2026 permanece sin precio.

El alcance no es una encuesta nacional, ni hay ponderadores. No se extrapolan resultados fuera de los activos y meses incluidos. Las fuentes carecen de fechas de revisión por registro; por ello los duplicados contradictorios no pueden resolverse dando preferencia a una versión.

5. Paso 3: análisis univariado


```
df[['crudo', 'gas', 'crudo_diario']].agg(  
    ['count', 'mean', 'median', 'std', 'skew', 'min', 'max']  
)
```



Indicador del crudo por activo-mes	Resultado
n válido	788
Media (barriles)	801,265.21
Mediana (barriles)	468,703.71
Desviación estándar (barriles)	738,050.31
Asimetría	0.906

La media supera la mediana y la asimetría es positiva: hay una cola de volúmenes altos. El histograma combina activos de tamaños muy distintos y no implica una distribución homogénea de pozos. La mediana describe mejor el centro de los registros, mientras la suma responde al volumen total observado. Ninguna de estas medidas demuestra crecimiento por sí sola.

6. Paso 4: evolución y asociación




Las sumas mensuales se acompañan del número de activos con crudo válido. La cobertura variable puede alterar el total aunque no cambie un activo individual. En el dashboard, los faltantes y combinaciones sin registro activan una advertencia; un mes sin registros no se dibuja como cero.

```
monthly = monthly_series(df)
counts = df.groupby('activo').crudo.count()
cohort = counts[counts == df.fecha.nunique()].index
balanced = monthly_series(df[df.activo.isin(cohort)])
```

Para la asociación temporal se seleccionan AM, AP, AU, CU, EY, IN, ITT, LI, OY, PA y SA: 11 activos con crudo válido en los 56 meses. Esta cohorte excluye LA y SH por sus faltantes, y AB16, AIT y AV por cobertura incompleta. La selección limita a qué activos se refiere la asociación.

Precio y producción se alinean una vez por mes. Quedan 55 meses con precio y 54 cambios desde febrero de 2022 hasta julio de 2026. Se usa volumen/días calendario para no confundir febrero con un mes de 31 días.

7. Paso 4: interpretación de la asociación



```
paired['cambio_crudo_pct'] = (  
    paired.crudo_diario.pct_change(fill_method=None) * 100  
)  
paired['cambioPrecio_pct'] = (  
    paired.precio_usd_barril.pct_change(fill_method=None) * 100  
)  
block_bootstrap_correlation(x, y, seed=2026, reps=2000, block=3)
```

Diagnóstico	Resultado
Pearson en niveles	0.127
Pearson entre cambios	0.017
Spearman entre cambios	0.064
IC exploratorio 95%, bloques de 3	[-0.202, 0.192]
Sensibilidad, bloques de 6	[-0.202, 0.200]

No se observa asociación lineal contemporánea fuerte en los cambios de esta cohorte. El intervalo incluye cero y asociaciones pequeñas de ambos signos; no demuestra independencia ni ausencia de efectos con rezagos. Los bloques circulares conservan dependencia local de pares, pero suponen suficiente estabilidad del proceso. Este intervalo no es garantía de cobertura del 95% ante cambios estructurales. No se usa un p-valor ingenuo ni se presenta un modelo predictivo.

8. Paso 5: limpieza y calidad trazable

Hallazgo real	Resultado / decisión
Copias exactas	9 filas extra; se consolidan por clave.
Claves repetidas	13 claves de agosto 2022; 13 filas redundantes en total.
Crudo de LA, agosto 2022	366668,06 vs. 366668,05: queda NA; no se promedia una contradicción.
Gas de AM, agosto 2022	713407,82 vs. 103,69: queda NA.
Gas de AU, agosto 2022	310275,38 vs. 310050,89: queda NA.
Diferencia binaria equivalente	Tolerancia absoluta 1e-6, rtol=0; no altera discrepancias mayores.
18 huecos interiores	17 meses de AV y junio 2024 de SH; no equivalen a cero.
AB16 ausente del catálogo	36 registros conservados con código y etiqueta sin catálogo.
Precio de agosto 2026	15 registros productivos sin precio; unión izquierda y sin imputación.
Ceros y atípicos	18 ceros de gas conservados; 52 marcas IQR de crudo diario y 42 de gas diario.

```
equivalent = np.allclose(values, values[0], atol=1e-6, rtol=0)
record[col] = float(np.mean(values)) if equivalent else np.nan
q1, q3 = g[var].quantile([.25, .75])
flag = (g[var] < q1 - 1.5*(q3-q1)) | (g[var] > q3 + 1.5*(q3-q1))
```

Resultado: 789 claves únicas, 788 crudos válidos y 787 gases válidos. Se conservan filas originales, conflictos, límites IQR y cobertura en reportes separados. Las sumas con datos faltantes son parciales. Los atípicos se calculan dentro de cada activo; no se eliminan volúmenes grandes por pertenecer a activos grandes.

Sensibilidad de limpieza: escoger la primera o última fila de LA alteraría el crudo en 0,01 barriles, pero asumir una preferencia seguiría sin evidencia. Para AM la discrepancia de gas es material. Se elige una política uniforme de NA por medida y se mantiene la observación disponible en la otra medida. Los ceros de gas de AV son ceros reportados, no imputaciones.

9. Paso 6: segmentación con n


Activo	2022	2023	2024	2025	2026
AB16	-	12	12	12	-
AIT	-	-	-	-	8
AM	12	12	12	12	8
AP	12	12	12	12	8
AU	12	12	12	12	8
AV	-	1	-	9	8
CU	12	12	12	12	8
EY	12	12	12	12	8
IN	12	12	12	12	8
ITT	12	12	12	12	8
LA	11	12	12	12	8
LI	12	12	12	12	8
OY	12	12	12	12	8
PA	12	12	12	12	8
SA	12	12	12	12	8
SH	12	12	11	12	8

Cada celda muestra n de crudo válido por activo-año, no población de pozos. Un guion significa que no hay registros del grupo. En 2026 todos los grupos tienen ocho meses; la advertencia n<12 permanece activa. En 2022 LA tiene 11 crudos válidos por la contradicción; en 2024 SH tiene 11 por la ausencia de junio.

```
groups = df.groupby(['activo', 'nombre_activo', 'anio']).agg(
    n_registros=('fecha', 'size'), n_crudo=('crudo', 'count'),
    n_gas=('gas', 'count'), n_precio=('precio_usd_barril', 'count'),
    mediana_crudo_diario=('crudo_diario', 'median')
)
```

El archivo reportes/segmentacion.csv contiene la tabla completa con medias, medianas, totales y n de cada medida. El umbral de 12 es una regla de cobertura de un ciclo anual; no un criterio universal de suficiencia estadística ni de privacidad. Las tres fuentes no contienen información personal.

10. Paso 6: comparación interanual homogénea



Indicador comparable	Enero-agosto 2025	Enero-agosto 2026
Activos completos	14	14
Meses por activo	8	8
Días calendario	243	243
Tasa diaria conjunta (barriles/día)	327,535.93	352,214.84


La variación de la cohorte es **+7.53%**. El cálculo pondera por días calendario (suma de barriles dividida por días distintos), en lugar de dar igual peso a meses de distinta duración. AIT y AB16 no aparecen en ambos períodos completos y se excluyen; no se equiparan sus códigos.

Indillana (IN) registra el mayor descenso absoluto de tasa dentro de esta cohorte: **-837.67 barriles/día**, equivalente a -6.25%. AV tiene pequeña escala absoluta: su variación porcentual no debe dominar la priorización operativa. Las tasas describen días calendario y no corrigen por días efectivos de operación.

Análisis aplicado | Pregunta 1 de 5

¿Mejoró la producción diaria conjunta entre enero-agosto de 2025 y 2026 al comparar los mismos activos?

Justificación - Basada en los datos: existen 14 activos con crudo válido en los ocho meses de ambos períodos. Cada año aporta 112 registros activo-mes y 243 días calendario. Esta coincidencia permite comparar sin mezclar un año parcial con uno completo ni incorporar códigos presentes solo en un período.



Respuesta basada en los datos: Sí, en volumen por día calendario de esta cohorte: pasa de 327.535,93 a 352.214,84 bbl/día, un aumento de 24.678,91 bbl/día (+7,53%). Se calcula sumando barriles y dividiendo por los días distintos del período; no se promedian sin ponderación las tasas mensuales.

Oportunidad identificada: El crecimiento conjunto es un avance observable del nivel productivo. Conviene estudiar los activos que aportan ese aumento para formular hipótesis de mejora.


Alcance y límite: n = 8 meses por activo y año: menos de un ciclo anual. El aumento no demuestra mayor eficiencia, rentabilidad ni efecto de una intervención. AIT y AB16 se excluyen por cobertura no comparable.

Fuente y cálculo: reportes/comparacion_interanual.csv; reportes/resumen.json. Cohorte: AM, AP, AU, AV, CU, EY, IN, ITT, LA, LI, OY, PA, SA y SH.

Análisis aplicado | Pregunta 2 de 5

¿Qué activos conviene revisar por sus caídas y cuáles aportan los mayores aumentos de producción?

Justificación - Basada en los datos: la comparación homogénea ofrece cambios absolutos y porcentuales para 14 activos, con n = 8 meses en cada año. Combinar ambas medidas evita que una caída porcentual grande en un activo pequeño desplace una pérdida de volumen mucho mayor.



Respuesta basada en los datos: 11 activos aumentan y 3 disminuyen. IN presenta la mayor caída absoluta: -837,67 bbl/día (-6,25%). AV cae más en porcentaje (-14,38%), pero su diferencia es solo -3,80 bbl/día. SH aporta +4.839,24 bbl/día (+9,67%) y SA +3.775,47 (+5,57%); AP crece +98,13% desde una base menor.

Oportunidad identificada: Priorizar la conciliación y revisión operativa de IN por la magnitud de la pérdida; investigar en SH y SA qué condiciones acompañaron los aumentos antes de intentar replicarlas.


Alcance y límite: La prioridad se basa únicamente en volumen observado. Sin costos, riesgos, pozos, paradas ni días operativos no se pueden atribuir causas ni recomendar una inversión específica.

Fuente y cálculo: reportes/comparacion_interanual.csv. Barras: diferencia absoluta; etiquetas: diferencia absoluta y variación porcentual.

Análisis aplicado | Pregunta 3 de 5

¿En qué activos se concentra la producción y dónde tendría mayor alcance una revisión de continuidad operativa?

Justificación - Basada en los datos: enero-agosto de 2026 contiene 120 registros válidos de crudo, distribuidos entre 15 activos con ocho meses cada uno. Esta cobertura común permite medir la contribución de cada activo al volumen total del período.



Respuesta basada en los datos: SA, AU y SH reúnen el 51,75% de los 88.304.451,13 barriles observados. El resto de los 12 activos aporta 48,25%. La participación mide concentración del volumen; no determina cuál activo es más eficiente.

Oportunidad identificada: Dar seguimiento prioritario a la continuidad de esos tres activos, junto con los criterios de seguridad y mantenimiento, porque representan más de la mitad del volumen observado.


Alcance y límite: n = 8 meses por activo; es una concentración de un período parcial. No es una estimación de reservas, de rentabilidad ni de producción nacional. Esta selección de 15 activos difiere de la cohorte interanual de 14.

Fuente y cálculo: data/procesados/produccion_limpia.csv, filtro anio = 2026 y mes <= 8. Participación = volumen del activo / volumen total observado.

Análisis aplicado | Pregunta 4 de 5

¿Las variaciones del precio del crudo acompañan las variaciones mensuales de producción de una cohorte estable?

Justificación - Basada en los datos: once activos tienen crudo válido durante los 56 meses productivos. Tras unir un solo precio por mes hay 55 meses con precio y 54 cambios mensuales pareados. El precio no se repite por activo para inflar el tamaño del análisis.



Respuesta basada en los datos: No se observa una asociación lineal contemporánea fuerte: Pearson $r = 0,017$ y Spearman = 0,064. El intervalo exploratorio del 95% por bloques de tres meses es $[-0,202; 0,192]$, que incluye cero. La nube de puntos no ofrece evidencia de una relación lineal marcada.

Oportunidad identificada: Mantener el precio como contexto y buscar variables operativas para explicar las variaciones de producción; estos resultados no respaldan usar solo el precio para fijar metas productivas.


Alcance y límite: $n = 54$ pares temporales, no independientes. Se analizan cambios en el mismo mes; no se estudian efectos rezagados ni causalidad. No se concluye que el precio nunca influya.

Fuente y cálculo: reportes/cambios_mensuales.csv y resumen.json. Remuestreo exploratorio: 2.000 réplicas, bloques de 3 meses y semilla 2026.

Análisis aplicado | Pregunta 5 de 5

¿Qué problemas de calidad deben resolverse antes de interpretar una variación como mejora o deterioro real?

Justificación - Basada en los datos: la auditoría encuentra 13 claves repetidas y tres celdas conflictivas. La cobertura muestra 18 huecos internos; AB16 tiene 36 registros sin nombre validado y agosto de 2026 carece de precio para sus 15 registros productivos.



Respuesta basada en los datos: La consolidación elimina 13 filas redundantes y deja 789 claves únicas. Persisten tres celdas por conciliar en agosto de 2022: crudo de LA y gas de AM y AU. Hay 17 huecos internos en AV y uno en SH (junio de 2024). Los bloques grises solo indican períodos fuera de la cobertura observada; no prueban cierre de operaciones.

Oportunidad identificada: Conciliar los tres conflictos con la fuente, confirmar el origen de los huecos, completar el catálogo de AB16 y solicitar el precio faltante. Estas acciones mejorarían la trazabilidad y la calidad de la comparación, sin inventar producción.

Alcance y límite: No reemplazar ausencias por cero ni borrar atípicos para mostrar mejoras. Se conservan 52 marcas IQR de crudo y 42 de gas. Cada celda del mapa representa un activo-mes; los colores no equivalen a magnitud de producción.

Fuente y cálculo: reportes/auditoria.json, cobertura.csv y data/procesados/produccion_limpiada.csv. Mapa: 896 combinaciones posibles = 789 observadas + 18 huecos + 89 fuera de cobertura.

11. Paso 7: decisiones sustentadas (1/2)

1. Priorizar la revisión de continuidad de SA, AU y SH

Evidencia: Sacha, Auca y Shushufindi concentran 51.75% del crudo de enero-agosto de 2026; 8 meses por activo. Es concentración del volumen observado.

Acción: Revisar semanalmente disponibilidad, paradas y mantenimiento de esos tres activos antes de reasignar recursos.

Responsable: Coordinación de operaciones y mantenimiento.

Indicador: Participación de los tres activos y tasa diaria por activo; activar revisión si cae más de 5% frente al mismo período previo.

Límite: El 5% es un umbral propuesto de gestión, no estimado ni normativo. No hay datos de costo, seguridad, disponibilidad ni reservas; no autoriza por sí solo inversiones.

2. Investigar la caída de Indillana en períodos comparables

Evidencia: IN registra 12,556 barriles/día en enero-agosto de 2026 y 13,393 en 2025: -6.25%, diferencia de -838 barriles/día (n=8 meses en cada año). La cohorte de 14 activos aumenta 7.53%.

Acción: Solicitar bitácoras de paradas y conciliación mensual de medición de IN; completar una revisión en 30 días.

Responsable: Ingeniería de producción del activo y responsable de datos.

Indicador: Variación interanual de tasa diaria y porcentaje de meses conciliados; objetivo de revisión: 100% de los 8 meses.

Límite: La reducción es descriptiva. No se atribuye a agotamiento o fallas sin evidencia operativa. Ocho meses no cubren una vuelta anual completa.

Estas son propuestas para un escenario profesional académico; no se afirma que la organización ya las haya aprobado o ejecutado. Los umbrales y plazos son decisiones de diseño explícitas.

12. Paso 7: decisiones sustentadas (2/2)

3. Corregir las brechas antes de certificar totales

Evidencia: Se encontraron 13 claves repetidas, 3 celdas contradictorias, 18 huecos interiores, AB16 sin catálogo y agosto de 2026 sin precio.

Acción: Conciliar AM, AU y LA de agosto de 2022 con la fuente, revisar las ausencias y completar la nomenclatura; mantener identificadas las sumas parciales.

Responsable: Administrador de datos y supervisor de medición.

Indicador: Claves duplicadas después de limpiar = 0; celdas conflictivas pendientes = 0 como meta; cobertura de catálogo = 100% como meta.

Límite: No sustituir faltantes por cero ni interpolar para cumplir la meta. Un hueco puede reflejar cobertura administrativa y requiere confirmación.

4. Separar la vigilancia del precio de las metas de producción

Evidencia: En 11 activos con cobertura constante, r entre cambios mensuales de tasa de crudo y precio es 0.017; $n=54$ meses pareados, IC exploratorio por bloques de 3 meses $[-0.202, 0.192]$.

Acción: Mantener el precio como indicador de contexto y actualizar la comparación mensual cuando exista el nuevo dato; usar variables operativas para investigar cambios productivos.

Responsable: Analista de planificación y analista comercial.

Indicador: Número de meses pareados, cobertura de la cohorte y correlación de cambios; no emitir conclusión cuantitativa con menos de 12 pares.

Límite: El intervalo incluye cero y valores positivos/negativos. No prueba independencia; no es un modelo de pronóstico ni una estimación causal. Precio $\times$ producción no representa ingresos efectivos.

13. Explicación técnica T1-T2

Correspondencia propuesta: los materiales y la rúbrica recibidos no incluyen los enunciados oficiales de T1-T8. Se organizan ocho apartados verificables que cubren carga, tipos, calidad, limpieza, integración, análisis, segmentación y reproducción. Esta numeración debe cotejarse si se entrega una guía adicional.

T1 | Carga y trazabilidad

read_excel/read_csv cargan las copias conservadas. SHA-256 impide analizar una versión distinta de la documentada. Path hace portables las rutas.

```
raw = pd.read_excel(path / 'produccion_original.xlsx')
prices = pd.read_csv(path / 'precios_original.csv')
assert hashlib.sha256(file.read_bytes()).hexdigest() == expected
```

Implementación completa: src/pipeline.py, función load_sources. El notebook muestra el código de la función y sus resultados ejecutados.

T2 | Estructura y tipos

to_numeric y to_datetime fallan ante valores inválidos; año/mes son enteros y activo es etiqueta nominal. info, shape y describe se muestran en el notebook.

```
d[col] = pd.to_numeric(d[col], errors='raise')
d[['anio', 'mes']] = d[['anio', 'mes']].astype('int64')
d['activo'] = d.activo.astype('string').str.strip().str.upper()
```

Implementación completa: src/pipeline.py, función clean_sources. El notebook muestra el código de la función y sus resultados ejecutados.

14. Explicación técnica T3-T4

T3 | Duplicados y contradicciones

La clave es año-mes-activo. Se consolidan copias exactas y equivalentes con tolerancia absoluta 1e-6. Cuando un volumen discrepa se asigna NA solo a esa medida. No se escoge la primera fila.

```
exact = d.duplicated(KEY + ['crudo', 'gas'])
for key, g in d.loc[~exact].groupby(KEY):
    equivalent = np.allclose(values, values[0], atol=1e-6, rtol=0)
    record[col] = np.mean(values) if equivalent else np.nan
```

Implementación completa: src/pipeline.py, función clean_sources. El notebook muestra el código de la función y sus resultados ejecutados.

T4 | Faltantes, ceros y atípicos

No se imputa precio ni volumen. Se conservan ceros de gas e IQR fuera de cercas por activo. Un faltante no es cero y un atípico no demuestra error.

```
q1, q3 = g[var].quantile([.25, .75])
lo, hi = q1 - 1.5*(q3-q1), q3 + 1.5*(q3-q1)
flag = (g[var] < lo) | (g[var] > hi)
# Se guarda la marca; no se filtra la observacion.
```

Implementación completa: src/pipeline.py, función clean_sources. El notebook muestra el código de la función y sus resultados ejecutados.

La conservación de valores extremos permite auditar sin cambiar la población analizada por conveniencia. La ausencia de precio afecta comparaciones con precio, no la disponibilidad del volumen productivo. Los CSV de conflictos y cobertura permiten revisar cada caso.

15. Explicación técnica T5-T6

T5 | Uniones y variables

merge many_to_one valida el catálogo y los precios. La unión izquierda retiene producción sin precio. Tasa diaria = volumen/días reales; log1p facilita describir asimetría.

```
clean = clean.merge(catalog, on='activo', how='left',
                    validate='many_to_one')
clean = clean.merge(prices, on='fecha', how='left',
                    validate='many_to_one')
clean['crudo_diario'] = clean.crudo / clean.fecha.dt.days_in_month
```

Implementación completa: src/pipeline.py, función clean_sources. El notebook muestra el código de la función y sus resultados ejecutados.

T6 | Resumen y asociación

Se distinguen suma, media y mediana. El precio se cuenta una vez por mes. Las correlaciones utilizan una cohorte constante; los cambios mensuales reducen la confusión por niveles y duración de los meses.

```
paired['cambio_crudo_pct'] = paired.crudo_diario.pct_change() * 100
paired['cambioPrecio_pct'] = paired.precio_usd_barril.pct_change() * 100
# Un par por mes de la cohorte, nunca un par por activo.
```

Implementación completa: src/pipeline.py, función analyze. El notebook muestra el código de la función y sus resultados ejecutados.

Los gráficos seleccionados responden a su variable: líneas para meses, barras ordenadas para contribuciones, histogramas y cajas para distribución y dispersión para asociación. No se usan pasteles ni ejes dobles para sugerir coincidencias visuales.

16. Explicación técnica T7-T8

T7 | Segmentación y n

groupby activo-año calcula n_registros y n válidos por medida. n<12 advierte cobertura inferior a una vuelta anual. La comparación 2026/2025 usa enero-agosto y 14 activos presentes en ambos períodos.

```
n = df.groupby(['activo', 'anio']).crudo.count()
alerta = n < 12
# Comparar enero-agosto con enero-agosto, mismo grupo de activos.
variacion = 100 * (tasa_actual/tasa_anterior - 1)
```

Implementación completa: src/pipeline.py, función analyze. El notebook muestra el código de la función y sus resultados ejecutados.

T8 | Reproducibilidad y validación

Semilla 2026 y 2.000 réplicas por bloques reproducen el diagnóstico. requirements, tests, notebook ejecutado y un comando reconstruyen los resultados. No se generan observaciones petroleras ficticias.

```
rng = np.random.default_rng(2026)
starts = rng.integers(0, n, size=int(np.ceil(n/block)))
idx = ((starts[:, None] + np.arange(block)) % n).ravel()[:n]
r_replica = np.corrcoef(x[idx], y[idx])[0, 1]
```

Implementación completa: src/pipeline.py, función block_bootstrap_correlation. El notebook muestra el código de la función y sus resultados ejecutados.

El remuestreo es una simulación del procedimiento estadístico, no de los datos de producción. Con el mismo entorno y semilla se repiten los intervalos. Bloques de 3 y 6 meses permiten examinar sensibilidad; cambiar la longitud puede cambiar la incertidumbre y no corrige todo cambio estructural.

17. Dashboard y validación funcional

El dashboard estático se construye desde la misma tabla depurada usada en Python. Incluye gráficos Plotly locales, de modo que no depende de una CDN para abrirlo. Puede servirse con `python app.py` o abrirse desde `dashboard/index.html`. La versión publicada ofrece el mismo análisis a través del enlace de entrega.

Elemento	Comportamiento comprobado
Indicadores	Volumen observado, tasa por día calendario, precio mensual medio y concentración de los tres mayores.
Filtros	Mes inicial, mes final, activo, crudo/gas y cobertura completa en el período.
Gráficos	Serie, barras de contribución, cajas de tasas, dispersión mensual y mapa de cobertura.
Tamaños	Tabla con n válido por activo y medida; alerta cuando $n < 12$ meses.
Vacíos y conflictos	Selección vacía y rango inverso muestran mensajes; contradicciones no se sustituyen por cero.
Exportación	CSV de la selección con fecha, medidas, banderas y filas de origen.
Decisiones	Referencia fija enero-agosto 2026/2025, declarada como independiente de los filtros.
Diseño	Vista de escritorio y 390 px sin desbordamiento; ejes numéricos conservan escala lineal tras filtrar.

Validación funcional: 17 comprobaciones aprobadas en Microsoft Edge sin ventana visible, usando la página local. No hubo errores JavaScript. Evidencia: `reportes/qa_dashboard.json` y `docs/dashboard.png`. La prueba local no sustituye la confirmación de publicación del servicio.

Guion de revisión: (1) abrir la selección inicial de 2026; (2) seleccionar IN; (3) cambiar a gas; (4) consultar AB16 en 2026 para ver el estado vacío; (5) ampliar a toda la historia y activar cobertura completa; (6) examinar calidad y descargar una selección. La advertencia de grupos pequeños acompaña la lectura, no bloquea la exploración.

La funcionalidad opcional WebMCP configura los mismos filtros de la interfaz cuando el navegador dispone de ella. Su compatibilidad nativa no se certifica en esta entrega; no es necesaria para utilizar el dashboard ni forma parte de la rúbrica.

18. Reproducibilidad y evidencia de la rúbrica

Entorno de referencia: Python 3.12.14. Instalar las versiones exactas de requirements.txt dentro de un entorno virtual. No se requieren credenciales para regenerar los análisis. El repositorio contiene fuentes pequeñas sin información personal; no se incluyen secretos del proyecto previo de clase.

```
python -m venv .venv
# Windows:
.venv\Scripts\python -m pip install -r requirements.txt
.venv\Scripts\python -m src.reproducir
.venv\Scripts\python -m unittest discover -s tests -v
.venv\Scripts\python app.py
```

Ruta	Contenido
data/crudos/	3 archivos intactos y manifiesto SHA-256
data/procesados/	Panel depurado y precios
src/	Carga, análisis, gráficos, notebook, PDF y dashboard
notebooks/	EDA ejecutado con código, resultados e interpretaciones
reportes/	Auditoría, cobertura, grupos, comparación, figuras y pruebas
dashboard/	Página interactiva compilada y biblioteca local
docs/	PDF único de entrega, enlaces y captura
tests/	Pruebas de integridad, política de limpieza y reproducibilidad

Criterio	Máximo	Evidencia en esta entrega
C1	10	Secciones 1-4; diccionario completo y usuario.
C2	10	Fuentes conservadas, SHA-256, semilla y calidad encontrada.
C3	20	Secciones 4-12 y notebook: siete pasos de S3_P1.
C4	15	Dashboard, n, alertas, filtros y 17 controles funcionales.
C5	20	Secciones 13-16; ocho apartados propuestos, código y justificación.
C6	15	Cuatro decisiones con evidencia, responsable, indicador y límite.
C7	5	README, requirements, estructura, scripts y pruebas.

La rúbrica recibida suma 95 puntos máximos, no 100. Esta matriz facilita comprobar la cobertura; no asigna una calificación. La correspondencia literal de T1-T8 queda sujeta a sus enunciados oficiales, que no estaban incluidos en los materiales entregados.

19. Referencias, trazabilidad y límites finales

Material de clase analizado

Material de Sabado_26	Uso en el proyecto
S3_P1_Ruano.ipynb	Orden de los siete pasos, mediana, IQR y segmentación con n.
S3_P2_Ruano.ipynb	Interpretación prudente de incertidumbre y correlación; no se fuerzan contrastes independientes.
S3_P3_ruano.ipynb	Prevención de fuga y necesidad de pregunta predictiva; no se añade un modelo innecesario.
S3_P4_Ruano.ipynb y mi_proyecto_ruano	Módulos, rutas portables, versiones, Git y minimización de datos.
S3_EDA_Critico_Reel_Turismo y S3_reel_Ruano	Suma frente a media, gráficos apropiados y límites de procedencia.
EDA_Produccion_Petrolera_Ecuador_Ruano	Antecedente temático y cohorte estable; no se reutilizó su CSV incrustado.

Referencias externas consultadas

Datos Abiertos Ecuador. [Producción Mensual Petroecuador](#). La ficha indexada indica volúmenes BPPM y MPC por activo. La apertura directa devolvió 403; no se descargó su diccionario ni se certificaron los archivos originales.

Banco Central del Ecuador. [Portal de información económica: Precio Petróleo Crudo Ecuatoriano](#). Definición del promedio mensual ponderado de exportaciones Oriente/Napo. Consulta: 2 de octubre de 2026, hora de Ecuador.

Identidad de los tres archivos

produccion_original.xlsx | 41438 bytes
ecfdc55ff37513772211970068df37c961ff472edf2917e55459f17db8a00e7c

precios_original.csv | 1937 bytes
4c9555a412907cf57e5d91af22928a78613fe89f6466429131e2b15aff3cec56

activos_original.csv | 244 bytes
63363bfadfc7b1bd5748256731f90221b35359efb9bb0dd967fcda0d4d48d98c

Límites: no hay datos de pozos, costos, días operativos, calidad del crudo ni causas de cambios. El precio agregado no representa ingresos de cada activo. Las coberturas administrativas no están documentadas. Las observaciones mensuales son dependientes. Las asociaciones y decisiones no se extrapolan a la producción nacional.